

UNIVERSIDAD PRIVADA ANTENOR ORREGO
FACULTAD DE INGENIERÍA
ESCUELA PROFESIONAL DE INGENIERÍA DE COMPUTACIÓN
Y SISTEMAS



PROYECTO DE CURSO

Semestre: 2026-10

Curso: APRENDIZAJE ESTADÍSTICO

Integrantes:

- FLORES LEONARDO ALBERTH JAIR
- PITA VERÁSTEGUI ANTHONY EDUARDO
- ROMERO ASMAT BRYANS ALDAIR
- SANTISTEBAN NOVOA JULIO ALEJANDRO
- GUTIERREZ GAMBOA FABRIZZIO MARTIN
- RUJEL ALVAREZ KEVIN DAVID
- AGUIRRE ANAMPA JAYRO

Docente:

SAGASTEGUI CHIGNE TEOBALDO HERNAN

Trujillo, 2026

Contenido

I.	Introducción.....	3
1.	Título del Proyecto	3
2.	Antecedentes.....	3
3.	Problema a resolver.....	9
4.	Objetivos.....	9
II.	Requerimientos	9
2.1.	Definición del Dominio	9
2.2.	Determinación de los Requisitos	10
2.2.1	Funcionales.....	10
2.2.2.	No funcionales	11
III.	Planteamiento del Data-Set, Pre-Procesamiento y Normalización	11
3.1.	Medidas, Datos, Base de Datos para la elaboración del Data-Set.....	11
3.2.	Normalización y/o Filtrado de Datos	18
3.3.	Planteamiento de:	20
IV.	Aprendizaje	22
4.1.	Planteamiento del Modelo de Aprendizaje.....	22
4.2.	Desarrollo e Implementación del Modelo	23
V.	Comprobación.....	25
5.1.	Entrenamiento del Modelo	25
VI.	Evaluación	27
6.1.	Métricas y Evaluación del Modelo	27
6.2.	Evaluación de desempeño del Sistema de AP del Proyecto	34
VII.	Despliegue del Sistema del Proyecto de Aprendizaje Estadístico	36
7.1.	Publicación del Proyecto y del Sistema en GITHUB	36
	Contenidos	¡Error! Marcador no definido.
7.1.1.	Pestaña de Documentación del Proyecto.....	37
7.1.2.	Pestaña de Código del Sistema	38
7.1.3.	Pestaña de Ejecución y Pruebas del Sistema.....	39
7.2.	Deploy del APP o Web del Sistema de Predicción, de Clasificación, de Segmentación o Asociación.....	43

I. Introducción

1. Título del Proyecto

"Aplicación de Modelo Predictivo de Credit Scoring: Una Estrategia para la Mitigación del Riesgo de Impago"

2. Antecedentes

El credit scoring surge como una herramienta utilizada por las entidades financieras para evaluar el riesgo crediticio de los solicitantes de préstamos. Su desarrollo se dio debido a la necesidad de agilizar y estandarizar los procesos de evaluación, ya que anteriormente las decisiones dependían únicamente del criterio subjetivo de los analistas financieros.

Según [Sánchez, P \(2015\)](#), el credit scoring es un sistema de modelos de decisión mediante el cual se calcula la probabilidad de que un sujeto sea capaz de devolver o no un crédito comercial. Este sistema se basa en modelos estadísticos que transforman la información obtenida del solicitante en medidas numéricas que sirven de apoyo para la toma de decisiones. De esta manera, las entidades financieras pueden determinar si conceden o rechazan un crédito según el nivel de riesgo del solicitante.

De manera similar, [López, I \(2019\)](#) define el credit scoring como un sistema de calificación de créditos que busca automatizar la toma de decisiones respecto a la concesión o rechazo de operaciones de riesgo, especialmente créditos. Esta automatización permite a las entidades financieras realizar evaluaciones más rápidas y objetivas sobre la capacidad de pago de los solicitantes.

Asimismo, [Sánchez, P \(2015\)](#) señala que actualmente la mayoría de entidades financieras utilizan sistemas de credit scoring debido a su rapidez y fiabilidad en la evaluación crediticia. Sin embargo, también existen ciertas limitaciones, especialmente la dependencia de la calidad y cantidad de los datos disponibles para realizar una correcta predicción del comportamiento del prestatario.

Por otro lado, para que el sistema funcione adecuadamente, es necesario analizar tanto las características del solicitante como las del crédito solicitado. Además, el proceso puede variar dependiendo de si el solicitante es una persona natural o jurídica, ya que cada caso requiere diferentes tipos de análisis de datos.

El origen del credit scoring se encuentra en los métodos estadísticos desarrollados para diferenciar grupos de población cuando las características entre ellos no podían identificarse fácilmente. Uno de los primeros aportes fue realizado por Fisher, quien introdujo técnicas

estadísticas de clasificación aplicadas inicialmente en el campo de la biología.

Posteriormente, Durand en 1941 aplicó estas técnicas al ámbito financiero para diferenciar clientes solventes e insolventes frente a un préstamo. Aunque este trabajo no tenía inicialmente una finalidad predictiva, representó uno de los primeros antecedentes del uso de métodos estadísticos en la evaluación crediticia.

Asimismo, [Tineo y Chuquipul \(2008\)](#) señalan que la primera empresa especializada en credit scoring fue creada por Fair e Isaac en la década de 1950 en San Francisco. Más adelante, con la expansión de las tarjetas de crédito en los años 60 y el desarrollo de los sistemas informáticos, las entidades financieras comenzaron a implementar masivamente estos modelos para optimizar sus procesos de evaluación crediticia.

Durante la década de 1980, el uso del credit scoring se extendió hacia préstamos personales, hipotecarios y créditos para pequeñas empresas. Posteriormente, en los años 90, también empezó a utilizarse en estrategias de marketing y segmentación de clientes, consolidándose como una herramienta ampliamente utilizada en el sector financiero.

El credit scoring es importante porque permite a las entidades financieras evaluar de manera objetiva el riesgo de otorgar un crédito, reduciendo la probabilidad de incumplimiento y facilitando decisiones rápidas y precisas. [\(Raymond Anderson, 2007\)](#)

Los autores enumeran los principales objetivos del credit scoring:

- Evaluación de riesgos objetiva: elimina la influencia del juicio personal en el proceso de decisión.
- Proceso costo eficiente: permite la aprobación rápida de los buenos créditos y el rechazo con la misma rapidez de los créditos que no están dentro del perfil de riesgos de la empresa, de tal forma que permite concentrarse en el análisis detallado de aquellos créditos que se sitúan en un área gris.
- Control estadístico del portafolio: el riesgo de cada cliente aceptado puede ser descrito en detalle con gran precisión estadística, permitiendo realizar un backtesting de las operaciones.
- Experimentación controlada: la empresa puede realizar simulaciones, por ejemplo, respecto a aceptar operaciones de alto riesgo, y estimar el impacto que podría tener en el largo plazo en la rentabilidad de su portafolio.

No obstante, se debe mencionar que, en ciertos segmentos de clientes, el juicio humano continúa siendo una herramienta indispensable en la evaluación del otorgamiento de un crédito, por lo cual, muchas veces

la técnica del juicio humano coexiste y se complementa con herramientas estadísticas. [\(Tamayo Medrano, 2017\)](#)

La calificación crediticia se fundamenta en el uso de modelos estadísticos y de aprendizaje automático que permiten estimar la probabilidad de incumplimiento de un cliente mediante el análisis de información histórica. Según [Gutiérrez Girault \(2007\)](#), estos modelos evalúan variables como el comportamiento financiero, el nivel de endeudamiento y el historial crediticio con el objetivo de predecir de manera sistemática el riesgo asociado a la concesión de un crédito. En la actualidad, diversas metodologías destacan por su equilibrio entre precisión e interpretabilidad.

Según [Rayo Cantón et al. \(2010\)](#), la regresión logística es la metodología más extendida en el ámbito bancario tradicional. Este modelo calcula la probabilidad de impago transformando variables como ingresos y edad en un valor entre 0 y 1, lo que facilita la definición de umbrales de decisión. Su principal fortaleza radica en la alta interpretabilidad, permitiendo que las instituciones financieras justifiquen sus decisiones ante los organismos reguladores. No obstante, su limitación reside en que asume relaciones lineales, lo que puede simplificar excesivamente el comportamiento del deudor.

En relación con enfoques no lineales, [Gutiérrez Girault \(2007\)](#) señala que los árboles de decisión permiten clasificar a los clientes mediante reglas lógicas de tipo "si-entonces". Este método destaca por su capacidad de visualizar claramente el proceso de evaluación y por no requerir supuestos estadísticos complejos. Aunque ofrecen buenos resultados ante datos no lineales, el autor advierte que pueden presentar problemas de sobreajuste si no se aplican técnicas de control adecuadas.

Para mitigar las debilidades de los modelos individuales, se han desarrollado técnicas de conjunto. Según [IBM \(s. f.\)](#), el bosque aleatorio combina múltiples árboles de decisión para mejorar la precisión y la capacidad de generalización del análisis. Al generar diversos árboles sobre distintos subconjuntos de datos y promediar sus predicciones, el modelo reduce significativamente el error y el sobreajuste. Sin embargo, esta arquitectura conlleva una mayor complejidad en su interpretación comparada con un árbol individual.

Finalmente, para entornos que exigen una evaluación aún más detallada, se emplean modelos de aumento de gradiente. Según [IBM \(s. f.\)](#), esta técnica construye árboles de manera secuencial, donde cada nueva estructura corrige los errores de la anterior, logrando una alta precisión predictiva. Variantes optimizadas como XGBoost y LightGBM son ampliamente utilizadas por su eficiencia en grandes volúmenes de datos, aunque su menor transparencia y mayor costo computacional pueden representar desafíos en contextos que demandan una explicación simple de la toma de decisiones.

La precisión de los modelos de calificación depende directamente de la selección de variables que reflejen el comportamiento del deudor. Según [Openbank \(s. f.\)](#), el factor de mayor peso es el historial de pagos, el cual registra si las obligaciones y facturas se han liquidado puntualmente o si han existido retrasos y moras, reflejando de forma directa la disciplina financiera del individuo.

Complementando esta visión, [Bank of America \(2026\)](#) y [Gamco \(2022\)](#) señalan que se deben considerar métricas de utilización y antigüedad. Entre ellas destaca el porcentaje de uso del crédito, que mide la relación entre el saldo utilizado y el límite disponible; una ratio elevada se interpreta generalmente como un riesgo de sobreendeudamiento. Asimismo, la duración del historial crediticio —que abarca desde la apertura de la primera cuenta hasta la más reciente— aporta una perspectiva sobre la estabilidad del cliente en el tiempo.

Por otra parte, [Mapfre \(2023\)](#) sostiene que las entidades incorporan la diversidad del portafolio de crédito (hipotecas, préstamos personales y tarjetas) y el número de solicitudes recientes, conocidas técnicamente como consultas de alto impacto. Finalmente, los modelos internos suelen integrar variables demográficas y financieras como la edad, la antigüedad laboral y la capacidad de endeudamiento, esta última expresada mediante la ratio deuda/ingresos, la cual determina la viabilidad del flujo de caja del solicitante frente a nuevas obligaciones.

El propósito fundamental de los sistemas de calificación trasciende la simple evaluación numérica. Según [Gamco \(2022\)](#) y estudios indexados en [SciELO \(2013\)](#), estos modelos buscan reducir la morosidad y el riesgo de impago mediante la identificación anticipada de perfiles con alta probabilidad de incumplimiento. Esta capacidad predictiva permite a las instituciones financieras mitigar pérdidas por cartera vencida al denegar créditos de alto riesgo o aplicar condiciones contractuales más restrictivas.

Por otro lado, la implementación de estas herramientas automatiza la toma de decisiones, sustituyendo o complementando los criterios subjetivos con modelos estadísticos y de inteligencia artificial. Según la [Fundación Mapfre \(s. f.\)](#), este proceso no solo acelera los tiempos de aprobación, sino que reduce significativamente los sesgos humanos en la evaluación. Asimismo, la automatización permite optimizar las condiciones del crédito —como tasas de interés y montos—, ofreciendo términos competitivos a perfiles sólidos y ajustando los costos para los perfiles más vulnerables en función de su nivel de riesgo.

Finalmente, el sistema actúa como un mecanismo para prevenir el sobreendeudamiento, ya que los modelos detectan cuando la carga financiera del solicitante es desproporcionada respecto a sus ingresos. De acuerdo con la [Fundación Mapfre \(s. f.\)](#), este enfoque preventivo contribuye a la reducción de costos operativos y fortalece la detección de

patrones asociados a fraudes o inconsistencias, consolidando así una gestión integral de riesgos dentro de las instituciones financieras.

En el ámbito financiero actual, la gestión del riesgo de crédito no se fundamenta únicamente en la precisión técnica de los modelos, sino que se encuentra estrechamente vinculada al cumplimiento de normativas internacionales. Según el [Comité de Basilea \(2017\)](#), los marcos regulatorios de Basilea II y III establecen que las instituciones financieras deben mantener niveles de capital proporcionales a sus riesgos para cubrir posibles pérdidas. Este organismo impulsa el uso de sistemas de calificación basados en calificaciones internas, los cuales permiten una medición más objetiva, granular y sensible al riesgo sobre el perfil del deudor.

Por otro lado, la implementación de estos modelos no solo responde a exigencias legales, sino también a una evolución en la transparencia del proceso. Según [García et al. \(2010\)](#), la integración de modelos de calificación crediticia representa un avance significativo hacia la equidad financiera. Al sustituir los criterios subjetivos por métricas verificables, se logra neutralizar los sesgos implícitos que históricamente han limitado el acceso al crédito para diversos sectores. En consecuencia, este enfoque no solo fortalece la integridad del sistema financiero, sino que promueve una cultura de responsabilidad y objetividad en la concesión de activos.

Como culminación de los aspectos teóricos, metodológicos y regulatorios expuestos anteriormente, es fundamental analizar cómo estos sistemas se materializan en escenarios financieros reales.

Diversos estudios previos demuestran que la aplicación de modelos de 'credit scoring' ha sido altamente efectiva para resolver los problemas de asimetría de información y exposición al riesgo en sectores de alto volumen y perfiles particulares como las microfinanzas y la banca minorista, ya que estos casos valían las técnicas de clasificación que aplicaremos en este proyecto.

En el ámbito de las microfinanzas, [Rayo, Lara y Camino \(2010\)](#) desarrollaron un modelo de 'credit scoring' adaptado a las normativas de Basilea II. Los autores señalaron que *"el desarrollo de modelos internos de calificación crediticia permite a las instituciones microfinancieras reducir la asimetría de información y optimizar la gestión de su cartera"* (p. 29). El proceso consistió en recopilar una base de datos histórica de instituciones microfinancieras y clasificar las variables de los prestatarios en dos grandes grupos: factores cuantitativos (financieros) y factores cualitativos (socioeconómicos). Posteriormente, aplicaron un análisis de regresión logística para identificar qué combinación de atributos discriminaba mejor entre clientes cumplidos y morosos. El desarrollo del modelo arrojó que atributos como la experiencia en el negocio, la relación entre ingresos y deudas, y la carga familiar tienen un alto poder predictivo. Este enfoque metodológico justifica directamente las decisiones tomadas

en nuestro proyecto, ya que, al igual que los autores citados, nosotros no solo evaluamos montos crediticios, sino que procesamos variables socioeconómicas y personales (como la edad, el estado civil y el tipo de vivienda) para perfilar el riesgo real de un individuo de manera más integral.

Por otro lado, enfocado en la banca minorista (*retail banking*), el estudio de [Dinh y Kleimeier \(2007\)](#) analizó el mercado financiero en Vietnam con el objetivo de construir un modelo de calificación crediticia propio para un banco comercial y llegó a la conclusión de que *"frente al dramático crecimiento del crédito de consumo y la mayor atención regulatoria al riesgo, el desarrollo de un marco de evaluación crediticia sólido es esencial"* (p. 472). Su proceso implicó extraer una muestra representativa de préstamos de consumo y contrastar la eficiencia de los métodos de evaluación tradicionales (basados en juicio del analista y relación con el cliente) frente a un modelo estadístico transaccional. Al utilizar técnicas de clasificación para estimar la probabilidad de incumplimiento en función de las características históricas del crédito, comprobaron que el modelo estadístico automatizado proyectaba con mucha mayor exactitud la morosidad y las pérdidas esperadas. La ruta trazada por esta investigación respalda nuestro objetivo central de optimizar el flujo de aprobación, confirmando que el uso de herramientas de aprendizaje estadístico y la aplicación de algoritmos de selección de atributos logran una eficiencia predictiva superior a la evaluación empírica tradicional.

Finalmente, complementando la precisión de estos sistemas, [Kwofie, Owusu-Ansah y Boadi, \(2015\)](#), llevaron a cabo una investigación centrada en predecir la probabilidad de *default* en solicitantes de préstamos. El procedimiento consistió en tomar un conjunto de datos históricos, realizar la limpieza y normalización de la información, y entrenar un algoritmo de regresión logística binaria para que aprenda a separar a los clientes en dos categorías de riesgo. El estudio demostró que variables como la duración del crédito y el historial de pagos previo se posicionan como los predictores más robustos para el algoritmo.

De hecho, los autores concluyen que "la aplicación de modelos de clasificación estadística binaria... al incumplimiento" (p. 48). Este precedente fundamenta la base técnica de nuestro trabajo con el 'dataset' seleccionado, validando nuestra elección de predecir una clase binaria (bueno o malo) y destacando la importancia de atributos históricos para construir un modelo estable, el cual será posteriormente evaluado mediante métricas avanzadas como la matriz de confusión.

3. Problema a resolver

¿De qué manera la aplicación de un modelo de aprendizaje estadístico sobre datos históricos permite determinar los factores críticos de riesgo y fortalecer la capacidad predictiva del *credit scoring*, minimizando los errores de clasificación de morosidad y optimizando la toma de decisiones en la asignación de créditos?

4. Objetivos

Objetivo General

Desarrollar y evaluar un modelo de aprendizaje estadístico en la clasificación del riesgo crediticio, mediante el análisis de variables socioeconómicas y financieras, para estimar la probabilidad de incumplimiento e identificar los factores críticos que afectan en la capacidad de pago de los solicitantes.

Objetivos Específicos

- Realizar el procesamiento y limpieza de datos de un dataset confiable, para garantizar la integridad y consistencia en el entrenamiento del modelo.
- Identificar las variables de mayor impacto para entender qué características definen realmente a un cliente con riesgo de mora.
- Desarrollar y ajustar algoritmos de clasificación que permitan calcular de manera automática la probabilidad de incumplimiento crediticio de cada solicitante.
- Evaluar el rendimiento del modelo mediante métricas avanzadas como la matriz de confusión, asegurando su capacidad predictiva y estabilidad.
- Optimizar el flujo de aprobación de créditos, estableciendo criterios de aceptación claros que faciliten una toma de decisiones más eficiente en comparación con los métodos de evaluación tradicionales.

II. Requerimientos

2.1. Definición del Dominio

El dominio del proyecto se circunscribe a la gestión del riesgo de crédito comercial y de consumo en el ámbito analítico de las instituciones financieras donde el objetivo de este negocio es mitigar la asimetría de información mediante la discriminación temprana entre perfiles solventes e insolventes

Para modelar este dominio de manera predictiva el ecosistema de datos a buscar debe estructurarse obligatoriamente bajo un enfoque analítico multidimensional que contenga información histórica de clientes sobre una dimensión de solvencia y liquidez compuesta por indicadores que reflejen la posición de efectivo del cliente saldos disponibles o capacidad de ahorro inmediato junto a una dimensión de comportamiento histórico basada en registros que evidencien la disciplina de pago previa del solicitante incidencias de morosidad o volumen de créditos concurrentes sumado a una dimensión de estabilidad socioeconómica conformada por variables demográficas de arraigo residencial y de inserción en el mercado laboral que justifiquen la continuidad de sus ingresos y finalmente una dimensión del riesgo operacional contractual orientada a las características intrínsecas del financiamiento solicitado tales como el destino de los fondos el plazo de amortización y las garantías asociadas.

El espacio de estados de este dominio culmina en una clasificación binaria que determina formalmente la viabilidad de la asignación del activo crediticio

2.2. Determinación de los Requisitos

2.2.1 Funcionales

- El sistema debe procesar la variable del nivel de ingresos del deudor.
- El sistema debe procesar la variable de saldos actuales del deudor.
- El sistema debe admitir la variable sobre la capacidad de ahorros.
- El sistema debe integrar la variable de antecedentes históricos del solicitante.
- El sistema debe integrar la variable de cumplimiento de pagos previos.
- El sistema debe capturar la variable referida al volumen de créditos activos concurrentes.
- El sistema debe registrar la variable de edad del solicitante.
- El sistema debe registrar la variable de estado civil del solicitante.
- El sistema debe procesar la variable de antigüedad laboral
- El sistema debe procesar la variable de tipo de ocupación.
- El sistema debe almacenar la variable de tipo de propiedad (vivienda).
- El sistema debe almacenar la variable de años de arraigo (tiempo en la vivienda).
- El sistema debe admitir la variable asociada al monto total de la línea de crédito solicitada.
- El sistema debe incorporar la variable temporal del plazo de amortización en meses del préstamo.

- El sistema debe procesar la variable categórica sobre el propósito final de los fondos.
- El sistema debe calcular una variable predictiva final de tipo binaria (buen/mal pagador).
- El sistema debe generar una gráfica de matriz de confusión basada en el error de la clasificación.
- El sistema debe calcular el poder de discriminación del modelo mediante el coeficiente de Gini.

2.2.2. No funcionales

- El sistema debe contar con un tiempo de respuesta de 1 segundo, generando predicciones en lo menor tiempo posible por solicitud procesada.
- El sistema debe ser desarrollado usando tecnologías de código abierto.
- El sistema debe ser robusto con datos incompletos o inconsistentes, aplicando técnicas de limpieza y Pre-procesamiento para conservar una calidad de análisis.
- El sistema debe garantizar la seguridad y confidencialidad de los datos cargados.
- El sistema debe estar entrenado y validado mediante técnicas como validación cruzada, asegurando la precisión y confiabilidad del modelo predictivo.

III. Planteamiento del Data-Set, Pre-Procesamiento y Normalización

3.1. Medidas, Datos, Base de Datos para la elaboración del Data-Set

Para la ejecución de este proyecto se utiliza el conjunto de datos de referencia internacional German Credit Data (credit-g.arff), desarrollado originalmente por el Prof. Dr. Hans Hofmann de la Universidad de Hamburgo (Alemania) publicado en 1994, disponible en el repositorio GitHub de la herramienta de WEKA (<https://github.com/Waikato/weka-3.8/blob/master/wekadocs/data/credit-g.arff>). Este conjunto de datos permite clasificar a los clientes según su riesgo crediticio, determinando si representan un cliente de “buen crédito” o “mal crédito”.

Este dataset pertenece al área de análisis financiero y evaluación de riesgo crediticio. Su objetivo principal es construir modelos predictivos capaces de identificar si una persona podrá cumplir correctamente con el pago de un préstamo.

- **Características Generales del Data-Set Credit-g.arff**

Característica	Descripción
Nombre del dataset	German Credit Data
Archivo utilizado	credit-g.arff
Tipo de problema	Clasificación
Área	Credit Scoring / Riesgo Crediticio
Número de instancias	1000 registros
Número de atributos	20 atributos predictivos + 1 atributo clase
Variable objetivo	class (bueno / malo)
Formato	ARFF
Herramienta utilizada	Weka

- Descripción de las variables:

Atributo	Descripción	Tipo de Variable	Valores
checking_status	Estado de la cuenta corriente existente del cliente.	Categórica (Nominal)	<0 (Saldo negativo), $0 \leq X < 200$ (Saldo bajo), ≥ 200 (Saldo óptimo o asignación de salario por mínimo 1 año), no checking (Sin cuenta corriente).
credit_history	Historial y disciplina de pago de créditos anteriores.	Categórica (Nominal)	no credits/all paid, all paid, existing paid, delayed previously, critical/other existing credit.
purpose	Finalidad o destino del financiamiento solicitado.	Categórica (Nominal)	new car, used car, furniture/equipment, radio/tv, domestic appliance, repairs, education, vacation, retraining, business, other.
savings_status	Fondos disponibles en cuentas de ahorros o bonos patrimoniales.	Categórica (Ordinal)	<100, $100 \leq X < 500$, $500 \leq X < 1000$, ≥ 1000 , no known savings.
employment	Antigüedad laboral en el puesto de trabajo actual.	Categórica (Ordinal)	unemployed, <1, $1 \leq X < 4$, $4 \leq X < 7$, ≥ 7 .
personal_status	Estado civil y sexo biológico del solicitante.	Categórica (Nominal)	male div/sep, female div/dep/mar, male single, male mar/wid, female single.
other_parties	Existencia de terceros responsables en la operación jurídica.	Categórica (Nominal)	none, co applicant, guarantor.
property_magnitude	Naturaleza del patrimonio material identificable del cliente.	Categórica (Nominal)	real estate, life insurance, car, no known property.
other_payment_plans	Planes de financiamiento externos a la entidad actual.	Categórica (Nominal)	bank, stores, none.
housing	Régimen de tenencia u ocupación de la vivienda residencial.	Categórica (Nominal)	rent, own, for free.
job	Nivel de cualificación u ocupación laboral.	Categórica (Ordinal)	unemployed/unskilled - non-resident, unskilled - resident, skilled employee / official, management/self-employed/highly qualified.
own_telephone	Disponibilidad de línea telefónica registrada a su nombre.	Categórica (Binaria)	none, yes.
foreign_worker	Condición de trabajador extranjero en el país.	Categórica (Binaria)	yes, no.
duration	Plazo de amortización contractual del crédito expresado en meses.	Numérica (Discreta)	Valores enteros en meses.

credit_amount	Monto total de la línea de crédito solicitada.	Numérica (Continua)	Valores monetarios positivos.
installment_commitment	Tasa de amortización periódica expresada en porcentaje respecto a los ingresos disponibles del cliente.	Numérica (Discreta)	Valores porcentuales.
residence_since	Tiempo de arraigo o permanencia cronológica en la vivienda residencial actual.	Numérica (Discreta)	Valores en años.
age	Edad cronológica del solicitante medida en años.	Numérica (Continua)	Valores de edad en años.
existing_credits	Volumen cuantitativo de créditos vigentes y activos contratados en esta misma entidad financiera.	Numérica (Discreta)	Número de créditos activos.
num_dependents	Cantidad de personas económicamente a cargo y dependientes del solicitante.	Numérica (Discreta)	Número de dependientes.
class	Indicador binario de clasificación del riesgo crediticio.	Variable Objetivo (Binaria)	good (Cliente solvente y bajo riesgo), bad (Alta probabilidad de mora o impago).

- **Instancias del Data-Set**

- 1. Cliente con historial crediticio crítico**

Instancia del Dataset:

'<0',6,'critical/other existing credit',radio/tv,1169, 'no known savings','>=7',4,'male single',none,4, 'real estate',67,none,own,2,skilled,1,yes,yes,Good

Descripción

Cliente masculino soltero con saldo bancario menor a 0 (<0) que solicitó un crédito de 1169 para la compra de radio o televisión. Presenta historial crediticio crítico y posee experiencia laboral mayor o igual a 7 años. Cuenta con vivienda propia y tiene 67 años de edad. El crédito fue clasificado como Good, indicando bajo riesgo crediticio.

2. Cliente con préstamo de largo plazo

Instancia del Dataset

'0<=X<200',48,'existing paid',radio/tv,5951,
'<100','1<=X<4',2,'female div/dep/mar',none,2, 'real
estate',22,none,own,1,skilled,1,none,yes,bad

Descripción

Cliente femenina divorciada/dependiente/casada con saldo bancario entre 0 y 200 ($0 \leq X < 200$). Solicitó un préstamo de 5951 destinado a radio o televisión, con una duración de 48 meses. Tiene experiencia laboral entre 1 y 4 años y 22 años de edad. El resultado final fue clasificado como Bad, indicando alto riesgo crediticio.

3. Cliente con crédito educativo

Instancia del Dataset

'no checking',12,'critical/other existing credit',
education,2096,'<100','4<=X<7',2,'male single', none,3,'real
estate',49,none,own,1, 'unskilled resident',2,none,yes,Good

Descripción

Cliente masculino soltero sin cuenta corriente (no checking) que solicitó un crédito de 2096 para fines educativos. Posee experiencia laboral entre 4 y 7 años, vivienda propia y 49 años de edad. El crédito fue clasificado como Good.

4. Cliente con garante y préstamo elevado

Instancia del Dataset

'<0',42,'existing paid',furniture/equipment,7882,
'<100','4<=X<7',2,'male single',guarantor,4, 'life
insurance',45,none,'for free',1, skilled,2,none,yes,Good

Descripción

Cliente masculino soltero con saldo menor a 0 (< 0) que solicitó un préstamo de 7882 para muebles y equipos. Cuenta con garante, vive gratuitamente (for free) y posee seguro de vida como propiedad. Tiene 45 años y el crédito fue evaluado como Good.

5. Cliente con antecedentes de retraso en pagos

Instancia del Dataset

'<0',24,'delayed previously','new car',4870,
'<100','1<=X<4',3,'male single',none,4, 'no known
property',53,none,'for free',2, skilled,2,none,yes,bad

Descripción

Cliente masculino soltero con historial de retrasos en pagos (delayed previously) que solicitó un crédito de 4870 para la compra de un auto nuevo. Vive gratuitamente y presenta propiedades desconocidas. Tiene 53 años y la clasificación final fue Bad.

6. Cliente con préstamo educativo de alto monto

Instancia del Dataset

'no checking',36,'existing paid',education,9055, 'no known
savings','1<=X<4',2,'male single', none,4,'no known
property',35,none,'for free', 1,'unskilled resident',2,yes,yes,Good

Descripción

Cliente masculino soltero sin cuenta corriente que solicitó un préstamo educativo de alto monto (9055). Posee ahorros desconocidos, vive gratuitamente y tiene 35 años. El crédito fue clasificado como Good.

7. Cliente con ahorros moderados

Instancia del Dataset

'no checking',24,'existing paid',
furniture/equipment,2835,'500<=X<1000', '>=7',3,'male
single',none,4, 'life insurance',53,none,own,1,
skilled,1,none,yes,Good

Descripción

Cliente masculino soltero sin cuenta corriente que solicitó un crédito de 2835 para muebles y equipos. Posee ahorros entre 500 y 1000, experiencia laboral mayor o igual a 7 años y vivienda propia. Tiene 53 años y el crédito fue clasificado como Good.

8. Cliente con empleo altamente calificado

Instancia del Dataset

'0<=X<200',36,'existing paid','used car',6948,
'<100','1<=X<4',2,'male single',none,2, car,35,none,rent,1, 'high
qualif/self emp/mgmt',1,yes,yes,Good

Descripción

Cliente masculino soltero con saldo bancario entre 0 y 200 (0<=X<200) que solicitó un préstamo de 6948 para la compra de un auto usado. Vive en alquiler (rent) y posee un empleo altamente calificado. Tiene 35 años y fue clasificado como Good.

9. Cliente adulto mayor con crédito de consumo

Instancia del Dataset

'no checking',12,'existing paid',radio/tv,3059,
'>=1000','4<=X<7',2,'male div/sep',none,4, 'real
estate',61,none,own,1, 'unskilled resident',1,none,yes,Good

Descripción

Cliente masculino divorciado/separado sin cuenta corriente que solicitó un crédito de 3059 para radio o televisión. Posee ahorros mayores a 1000 y vivienda propia. Tiene 61 años y el crédito fue clasificado como Good.

10. Cliente desempleado con riesgo crediticio

Instancia del Dataset

'0<=X<200',30,'critical/other existing credit', 'new
car',5234,'<100',unemployed,4, 'male mar/wid',none,2,car,28,
none,own,2,'high qualif/self emp/mgmt', 1,none,yes,bad




Descripción

Cliente masculino casado/viudo con saldo bancario entre 0 y 200 ($0 \leq X < 200$) que solicitó un préstamo de 5234 para la compra de un auto nuevo. Se encuentra desempleado y posee antecedentes crediticios críticos. Tiene 28 años y el resultado final fue clasificado como Bad.

3.2. Normalización y/o Filtrado de Datos

- **Carga del dataset:**

Abrimos WEKA seleccionamos Explorer y en el apartado de Process – Open File adjuntamos nuestro archivo credit-g.arff con doble-click.



- **Filtrado de datos:**

Eliminar valores faltantes:

Ahora usaremos el filtro de **ReplaceMissingValues** para eliminar valores faltantes.




Relation: german_credit-weka.filters.unsupervised.attribute....	Attributes: 15
Instances: 1000	Sum of weights: 1000

No hubo valores faltantes.


Eliminar atributos que no aportan información útil para el modelo:

Aplicamos el filtro de **RemoveUseless** para garantizar que el dataset contenga información relevante.



Balaneo de la variable objetivo

Para corregir el desbalanceo de la variable objetivo, ya que 70% son buenos pagadores y el 30% son malos pagadores, para ello, usamos SMOTE que va a analizar las instancias de la clase minoritaria para crear 400 instancias generalizando su información.




The screenshot shows the Weka GUI's 'Attributes' list. The 'Class' dropdown menu is open, showing the 'good' and 'bad' classes. The 'good' class has a count of 700 and a weight of 700.0. The 'bad' class has a count of 300 and a weight of 300.0. The 'Visualize All' button is visible.

No.	Name	Type
1	checking_status	String
2	duration	Integer
3	credit_history	String
4	purpose	String
5	credit_amount	Integer
6	savings_status	String
7	employment	String
8	personal_status	String
9	other_parties	String
10	property_magnitude	Integer
11	age	Integer
12	other_payment_plans	String
13	housing	String
14	foreign_worker	String
15	class	String

NOTA: Ahora el dataset va a manejar 1400 instancias debido al uso del filtro SMOTE.

- **Normalización:**

Aplicamos el filtro de Normalize. Esto pone todos los números en un rango de 0 a 1 para que ninguna variable "gane" por ser más grande.




3.3. Planteamiento de:

- **Data-Set de entrenamiento:**

Volumen: 980 registros de solicitantes de crédito (70% del total).

Distribución: Aproximadamente balanceado entre clientes buenos y malos tras el proceso de SMOTE.

Propósito: Permitir el aprendizaje del modelo mediante la identificación de patrones entre variables financieras y la probabilidad de incumplimiento.




- Data-Set de Pruebas:

Volumen: 280 registros de solicitantes de crédito (20% del total).

Distribución: Mantiene proporción similar entre clases bueno y malo.

Propósito: Evaluación del rendimiento del modelo con datos no vistos durante el entrenamiento.



- Data-Set de Validación por “Cross-Validation”:

Técnica: Validación cruzada con 10 partes.

Volumen: Se utiliza el 100% del dataset (1,400 registros) dividido en 10 subconjuntos.

Distribución: En cada iteración se mantiene la proporción de clases bueno y malo.

Propósito: Validar el modelo de manera más robusta, reduciendo el sesgo de una sola partición.

IV. Aprendizaje

4.1. Planteamiento del Modelo de Aprendizaje

Para el desarrollo de este proyecto de riesgo crediticio, se seleccionaron tres algoritmos con enfoques matemáticos y estructurales mencionados en los antecedentes.

A continuación, se justifica la elección de cada uno de ellos en el entorno de Weka:

1. Regresión Logística

Es el estándar de la industria financiera y bancaria. Al ser un modelo lineal paramétrico, calcula la probabilidad de que un cliente caiga en default mediante la función logística.

Su gran ventaja es la interpretabilidad. Weka devuelve los coeficientes exactos de cada variable, lo que permite explicar fácilmente cómo afecta cada factor (por ejemplo, el nivel de ingresos o el historial de deudas) al otorgamiento del crédito, cumpliendo con las normativas de transparencia financiera.

2. Random Forest

Es un método de ensamble basado en el embolsado (Bagging). Crea múltiples árboles de decisión independientes durante el entrenamiento y combina sus predicciones mediante votación mayoritaria.

Los datos de solicitudes de crédito suelen ser complejos, con relaciones no lineales y datos faltantes. Random Forest es ideal porque reduce drásticamente el riesgo de sobreajuste (overfitting) en comparación con un árbol de decisión simple (J48), y maneja de forma nativa variables categóricas y numéricas sin requerir una normalización estricta.

3. Gradient Boosting

En Weka estándar, el equivalente directo y más potente de Gradient Boosting es LogitBoost (clasificación aditiva logística) o AdaBoostM1 combinado con árboles binarios.

Es un algoritmo de ensamble secuencial (Boosting). A diferencia de Random Forest, los árboles no se crean de forma independiente, sino que cada nuevo árbol se entrena para corregir específicamente los errores de clasificación cometidos por los árboles anteriores.

En las bases de datos de créditos existe un fuerte desbalanceo de clases (hay muchos clientes buenos y pocos clientes morosos). Los algoritmos de Boosting son penalizadores agresivos de los errores; por lo tanto, se enfocan con mayor intensidad en aprender a identificar correctamente a esa pequeña minoría de clientes de alto riesgo, lo que suele traducirse en el mayor AUC-ROC del experimento.

4.2. Desarrollo e Implementación del Modelo

La fase de implementación de los clasificadores supervisados seleccionados se ejecuta en el entorno de software WEKA. Para garantizar una comparación equitativa y mitigar el riesgo de sobreajuste (overfitting), se somete a todos los algoritmos al mismo protocolo de partición de datos, aplicando simultáneamente un control riguroso de sus respectivos hiperparámetros de control.

- **Protocolo Transversal de Partición por Validación Cruzada (10-Fold Cross-Validation)**

Para evaluar el rendimiento real de los tres modelos ante datos no observados y asegurar la estabilidad de las métricas en un entorno de riesgo crediticio, se implementa el método de validación cruzada con $K = 10$. El dataset se fragmenta de forma estratificada en 10 subconjuntos independientes. Cada algoritmo ejecuta 10 iteraciones consecutivas, utilizando en cada una de ellas 9 pliegues para el aprendizaje y reservando el pliegue restante estrictamente para la fase de testeo, promediando finalmente los resultados estadísticos.

- **Implementación Específica por Algoritmo:**

- 1. Regresión Logística (Functions -> Logistic)**

El modelo se implementa con el fin de establecer una línea base estadística altamente interpretable, controlando la complejidad matemática mediante los siguientes parámetros:

Estabilización por Regularización (ridge = 1.0E-8):

Se configura un parámetro de cresta (Ridge) pequeño pero estrictamente activo. Esto aplica una penalización L2 sobre los coeficientes del modelo, evitando que los pesos de las variables financieras adquieran valores extremadamente altos debido a problemas de multicolinealidad latentes en los datos de los clientes.

Criterio de Parada y Convergencia (maxIts = -1):

Se establece la opción por defecto (-1) para permitir que el algoritmo de optimización Quasi-Newton (Quasi-Newton BFGS) ejecute las iteraciones necesarias de forma libre hasta lograr la convergencia matemática absoluta de la función de verosimilitud, garantizando estimaciones estables de las probabilidades de default.

2. Bosques Aleatorios (Trees -> RandomForest)

La implementación de este clasificador de ensamble se orienta a capturar relaciones no lineales complejas mediante la combinación de múltiples árboles, controlando su varianza a través de las siguientes restricciones:

Dimensión del Ensamble (numIterations = 100 o numTrees):

Se define la construcción obligatoria de 100 árboles de decisión independientes. Este volumen garantiza el cumplimiento de la ley de los grandes números para ensambles, permitiendo que el error de generalización converja de forma óptima sin incurrir en un costo computacional excesivo.

Control de Profundidad Absoluta (maxDepth = 0 - Ilimitado):

Se permite que los árboles individuales crezcan sin una restricción de altura predefinida (0), asegurando que cada clasificador base reduzca su sesgo al máximo. No obstante, el sobreajuste se controla de manera intrínseca mediante la técnica de embolsado (Bagging) y la selección aleatoria de atributos en cada división.

Restricción de Tamaño de Nodos (minNumObj = 1.0):

Se mantiene el umbral mínimo por defecto para los nodos terminales de los árboles individuales, permitiendo la máxima pureza local en las hojas, dado que la varianza final del sistema será mitigada por el promedio de los 100 árboles del bosque.

3. Potenciación Logística (Meta -> LogitBoost)

Como técnica de ensamble secuencial (Boosting), este modelo se configura con un enfoque agresivo para la detección de la clase minoritaria (clientes morosos), parametrizándose de la siguiente manera:

Algoritmo Base de Clasificación (classifier = Trees -> DecisionStump):

Se seleccionan tocones de decisión (árboles de un solo nivel de división) como clasificadores débiles. Esto obliga al meta-algoritmo a construir la frontera de decisión final de manera aditiva, combinando múltiples reglas simples de screening crediticio.

Ciclos de Optimización Secuencial (numIterations = 50):

Se restringe el proceso de potenciación a 50 iteraciones consecutivas. Al limitar los pasos de aprendizaje secuencial, se impide que el modelo intente memorizar los valores atípicos (outliers) o el ruido extremo del dataset de créditos, deteniendo el aprendizaje en un punto óptimo de generalización.

Suavizado de Contribución (shrinkage = 1.0):

Se mantiene el factor de contracción por defecto para asegurar que cada nuevo tocón de decisión aporte con todo su peso teórico a la corrección de los errores residuales acumulados en las iteraciones previas.

V. Comprobación

5.1. Entrenamiento del Modelo





El proceso de experimentación y comprobación se ejecutó en el módulo Explorer de WEKA, la cual emula con precisión los entornos de producción en el análisis de riesgo crediticio bancario. Para ello, el espacio muestral se dividió físicamente en dos conjuntos independientes: training_data (destinado exclusivamente al aprendizaje) y testing_data (reservado estrictamente como control ciego para la evaluación).

El flujo metodológico e implementación en el software se estructuró bajo los siguientes pasos secuenciales:

- Fase de Carga:

En primera instancia, se importó el archivo training_data en la pestaña Preprocess. Al redireccionarse al módulo Classify, cada algoritmo (Logistic, RandomForest y LogitBoost) procesó estas instancias para ajustar sus parámetros internos, pesos y fronteras de decisión probabilísticas. Mantener las 20 variables originales en


este archivo permitió a los modelos extraer la máxima variabilidad y correlación financiera de los clientes sin sesgos previos.



- Fase de Training y Testing:

Para evaluar la verdadera capacidad de generalización y asegurar que los modelos no memorizaron el ruido de los datos (mitigación de overfitting), se acudió al apartado Test options de WEKA, activando la directriz Supplied test set. A través del comando Set..., se vinculó

de forma externa el archivo testing_data. De este modo, una vez consolidada la estructura matemática de cada clasificador en la fase de desarrollo e implementación del modelo, WEKA la sometió a este conjunto de prueba complementario, garantizando que las métricas resultantes reflejen el desempeño del sistema ante perfiles crediticios completamente inéditos.



VI. Evaluación

6.1. Métricas y Evaluación

- REGRESIÓN LOGÍSTICA

Correctly Classified Instances	340	80.9524 %
Incorrectly Classified Instances	80	19.0476 %
Kappa statistic	0.619	
Mean absolute error	0.2647	
Root mean squared error	0.3884	
Relative absolute error	52.9362 %	
Root relative squared error	77.6472 %	
Total Number of Instances	420	

Matriz de confusión

```
=== Confusion Matrix ===  
  
   a    b   <-- classified as  
167  38 |   a = good  
 42 173 |   b = bad
```

- **Verdaderos Positivos (TP = 167):** Clientes solventes que el modelo identificó correctamente como de bajo riesgo.
- **Verdaderos Negativos (TN = 173):** Clientes morosos que el sistema detectó con éxito, permitiendo denegar el crédito a tiempo.
- **Falsos Positivos (FP = 38):** Clientes solventes catalogados erróneamente como morosos (costo de oportunidad por crédito no colocado).
- **Falsos Negativos (FN = 42):** El error más crítico y costoso para la institución financiera. Representa a 42 clientes morosos que fueron clasificados como "buenos", lo que se traduce directamente en pérdidas por cartera vencida (default).

Recall

```
Recall  
0.815  
0.805
```


- Para la clase good, el Recall es de 0.815. Significa que el modelo es capaz de capturar e incorporar al circuito comercial al 81.5% de la demanda de clientes solventes.
- Para la clase bad, el Recall alcanza un 0.805. Esto demuestra que el algoritmo tiene una alta efectividad de blindaje, detectando de forma temprana al 80.5% de las solicitudes fraudulentas o insolventes.

F1-SCORE por clases

F-Measure
0.807
0.812

- Clase good (F1-Score = 0.807): Manifiesta un rendimiento robusto y equilibrado, asegurando que el otorgamiento de créditos mantenga un nivel mínimo de falsas alarmas comerciales.
- Clase bad (F1-Score = 0.812): Este es un resultado sobresaliente para una Regresión Logística paramétrica. Al superar el umbral del 80%, se confirma que el modelo no sacrificó la precisión por capturar morosos; es altamente certero cuando genera una alerta de denegación de crédito.

Curva roc/coeficiente de gini



ROC Area
0.863
0.863
0.863

El área bajo la curva ROC (AUC) y el coeficiente Gini constituyen las métricas reina en la validación de Credit Scoring, midiendo la capacidad del modelo para ordenar a los clientes de menor a mayor riesgo independientemente del umbral de corte seleccionado.

Área Bajo la Curva (ROC Área = 0.863): De acuerdo con la literatura de aprendizaje estadístico, un AUC de 0.863 posiciona al clasificador en un nivel de excelente capacidad de discriminación. Existe un 86.3% de probabilidad de que el modelo asigne correctamente una probabilidad de incumplimiento más alta a un cliente moroso elegido al azar que a un cliente solvente.

Coeficiente Gini: A partir del resultado de WEKA, se computa formalmente el Coeficiente Gini mediante la transformación lineal estándar:

$$\text{Gini} = 2 \times \text{AUC} - 1$$

$$\text{Gini} = 2 \times 0.863 - 1 = 0.726$$

Un Gini de 0.726 (72.6%) convalida científicamente el modelo ante cualquier comité de riesgos regulatorio. Indica una separación robusta entre las curvas de distribución de clientes aptos y no aptos, asegurando la rentabilidad de las políticas de colocación del proyecto.

- **RANDOM FOREST**

Correctly Classified Instances	341	81.1905 %
Incorrectly Classified Instances	79	18.8095 %
Kappa statistic	0.6242	
Mean absolute error	0.2782	
Root mean squared error	0.3604	
Relative absolute error	55.6316 %	
Root relative squared error	72.0599 %	
Total Number of Instances	420	

Matriz de confusión

```

=== Confusion Matrix ===

  a    b  <-- classified as
173  32 |   a = good
 47 168 |   b = bad

```

- **Verdaderos Positivos (TP = 173):** Clientes de bajo riesgo que el bosque aleatorio clasificó adecuadamente, maximizando la eficiencia comercial del banco.
- **Verdaderos Negativos (TN = 168):** Clientes insolventes identificados con éxito por el modelo, protegiendo activamente los fondos de la institución.
- **Falsos Positivos (FP = 32):** Clientes solventes que fueron rechazados por el sistema al clasificarse erróneamente como morosos (costo de oportunidad).
- **Falsos Negativos (FN = 47):** Clientes de alto riesgo aceptados erróneamente en el portafolio de créditos. Representa el error más crítico para el banco, ya que estas 47 instancias se traducen en pérdidas directas por impago (default).

Recall

```

Recall
0.844
0.781

```

- Para la clase good, el Recall es de 0.844. Esto demuestra un alto dinamismo comercial, capturando exitosamente al 84.4% de la masa de clientes aptos.

- Para la clase bad, el Recall se sitúa en 0.781. El modelo es capaz de detectar y frenar de forma temprana al 78.1% de los perfiles potencialmente morosos.


F1-SCORE por clases

```
F-Measure
0.814
0.810
```

- Clase good (F1-Score = 0.814): Refleja una alta estabilidad en la aprobación de créditos, reduciendo las tasas de fricción con los clientes solventes.
- Clase bad (F1-Score = 0.810): A pesar de la naturaleza compleja y no lineal de los árboles individuales, el promedio del ensamble consolida una métrica muy sólida (81.0%), garantizando que las denegaciones de crédito estén bien fundamentadas estadísticamente.

Curva roc/coeficiente de gini

```
ROC Area
0.895
0.895
0.895
```



Estas métricas determinan la potencia del modelo para ordenar y clasificar a los solicitantes por su nivel de riesgo real, independientemente del punto de corte probabilístico utilizado.

Área Bajo la Curva (ROC Área = 0.895): Este resultado es extraordinario. Un AUC de 0.895 roza el umbral de la excelencia analítica en Credit Scoring. Significa que existe un 89.5% de probabilidad de que el modelo diferencie correctamente a un cliente en mora de uno solvente ante dos casos extraídos al azar, superando con creces la capacidad predictiva de los modelos lineales tradicionales.

Coeficiente Gini: Utilizando la ecuación matemática de transformación estándar a partir del AUC devuelto por WEKA:

$$\text{Gini} = 2 \times \text{AUC} - 1$$

$$\text{Gini} = 2 \times 0.895 - 1 = 0.790$$

Un Gini de 0.790 (79.0%) ratifica la superioridad de este enfoque de ensamble para la gestión del riesgo de crédito. Esta métrica demuestra matemáticamente que la combinación de múltiples árboles reduce la varianza y genera una separación de perfiles sumamente nítida, optimizando las políticas de mitigación de pérdidas del proyecto.

- **LOGITBOOST**

Correctly Classified Instances	336	80	%
Incorrectly Classified Instances	84	20	%
Kappa statistic	0.6001		
Mean absolute error	0.2609		
Root mean squared error	0.3817		
Relative absolute error	52.1683	%	
Root relative squared error	76.3197	%	
Total Number of Instances	420		

Matriz de confusión

```

=== Confusion Matrix ===
      a    b    <-- classified as
167  38 |    a = good
 46 169 |    b = bad

```

- **Verdaderos Positivos (TP = 167):** Solicitudes de bajo riesgo aprobadas correctamente por el sistema.
- **Verdaderos Negativos (TN = 169):** Perfiles insolventes bloqueados con éxito por la estructura de boosting, garantizando la protección del capital de la institución.
- **Falsos Positivos (FP = 38):** Clientes solventes catalogados por error como de alto riesgo, elevando el costo de oportunidad comercial de la campaña.
- **Falsos Negativos (FN = 46):** Clientes morosos que lograron superar los filtros aditivos del modelo y obtuvieron la aprobación. Este es el indicador crítico de pérdida crediticia latente que el banco busca monitorear.

Recall

```
Recall
0.815
0.786
```

- Para la clase good, el Recall es de 0.815. Indica que el modelo aprueba de manera efectiva al 81.5% de los perfiles óptimos que solicitan crédito.
- Para la clase bad, el Recall alcanza un sólido 0.786. Esto demuestra la fortaleza analítica del Boosting: al entrenar secuencialmente sobre los errores, el algoritmo se vuelve altamente sensible para capturar al 78.6% de la minoría morosa.


FI-SCORE por clases

```
F-Measure
0.799
0.801
```

- Clase good (F1-Score = 0.799): Presenta una estabilidad muy alta, rozando el 80%, garantizando fluidez en la colocación de créditos comerciales.
- Clase bad (F1-Score = 0.801): Superar el umbral del 80% en la detección de morosidad confirma que el modelo es altamente certero y consistente cuando genera una alerta de rechazo.

Curva roc/coeficiente de gini

```
ROC Area
0.871
0.871
0.871
```



Estas métricas determinan la potencia del clasificador para ordenar probabilísticamente a los clientes según su riesgo crediticio real.

Área Bajo la Curva (ROC Área = 0.871): El resultado se ubica firmemente en el rango de excelente capacidad de discriminación. Un AUC de 0.871 valida que el proceso iterativo basado en tocones de decisión (DecisionStump) logró consolidar una frontera de separación sumamente potente, superando a la Regresión Logística (0.863).

Coeficiente Gini: Computado formalmente a partir de la métrica de WEKA mediante la fórmula de transformación lineal:

$$\text{Gini} = 2 \times \text{AUC} - 1$$

$$\text{Gini} = 2 \times 0.871 - 1 = 0.742$$

Un Gini de 0.742 (74.2%) confirma que LogitBoost es una alternativa sumamente potente para la gestión del riesgo de crédito en el proyecto, garantizando una separación clara y robusta entre las curvas de distribución de clientes aptos e insolventes.

6.2. Evaluación de desempeño del Sistema de AP del Proyecto

Para elegir el mejor modelo para nuestro sistema de Credit Scoring, pusimos a competir los resultados que cada algoritmo obtuvo con el grupo de datos de prueba (las 420 instancias de control). No nos quedamos solo con la precisión general; analizamos el equilibrio entre la puntería del modelo, su capacidad para ordenar a los clientes según su riesgo y el costo económico que genera cada tipo de error.

El rendimiento de cada algoritmo se resume en la siguiente tabla:

Modelo Algorítmico	Accuracy (Exactitud)	F1-Score (Clase Bad)	Área ROC (AUC)	Coeficiente Gini	Falsos Negativos (FN)
Regresión Logística	80.95%	0.812	0.863	72.60%	42
Random Forest	81.19%	0.81	0.895	79.00%	47
LogitBoost	80.00%	0.801	0.871	74.20%	46

Si miramos los números fríamente, Random Forest es el ganador en capacidad predictiva. Alcanzó la mayor exactitud (81.19%) y un área ROC sobresaliente de 0.895, lo que nos da un Coeficiente Gini del 79.0%. Esto demuestra que combinar muchos árboles de decisión funciona mucho mejor que los modelos lineales para entender el perfil de los clientes del German Credit. Este modelo nos permitiría ordenar a los solicitantes de menor a mayor riesgo con mucha facilidad.

Sin embargo, en el negocio bancario hay un detalle crucial: el error más caro es el Falso Negativo, es decir, darle un crédito a alguien que no va a pagar. Al revisar las matrices de confusión, la Regresión Logística clásica sacó la cara aquí, cometiendo solo 42 errores de este tipo frente a los 47 de Random Forest. Esto nos dice que el modelo tradicional es un poco más conservador y precavido con las pérdidas directas.

A pesar de esa pequeña ventaja de la Regresión Logística, el dictamen final es que el mejor modelo para el proyecto es Random Forest. Su superioridad en el Coeficiente Gini (79.0%) garantiza que el sistema será mucho más estable frente a nuevos clientes a largo plazo.

Para conocer cómo elige Random Forest y entender los criterios internos que utiliza el algoritmo para tomar sus decisiones, se generaron los siguientes datos de relevancia estructural mediante el software WEKA:

```
Ranked attributes:
0.23061    2 duration
0.21735    1 checking_status
0.2102     13 age
0.20102    11 residence_since
0.15306     6 savings_status
0.15       8 installment_commitment
0.13061     3 credit_history
0.11531     7 employment
0.10714    16 existing_credits
0.09643     4 purpose
0.09102     5 credit_amount
0.08571    18 num_dependents
0.06327    19 own_telephone
0.05969     9 personal_status
0.02857    12 property_magnitude
0.02296    15 housing
0.01837    10 other_parties
0.01143    17 job
0.0102     20 foreign_worker
0.00204    14 other_payment_plans
```

A partir de la captura anterior, podemos observar tales resultados y analizarlos bajo tres niveles de importancia para el negocio crediticio:

En primer lugar, salta a la vista que los verdaderos pilares de la decisión son la duración del préstamo (duration con 0.23), el estado de la cuenta corriente (checking_status con 0.21) y la edad (age con 0.21). Esto nos indica que el modelo no opera a ciegas; por el contrario, prioriza el tiempo que el banco estará expuesto al riesgo, la liquidez inmediata del cliente y su estabilidad demográfica, los cuales son los tres factores más lógicos en cualquier evaluación financiera real.

En segundo lugar, vemos un grupo de variables con un peso moderado (entre 0.11 y 0.20) como el tiempo de residencia (residence_since), el nivel de ahorros (savings_status) y el historial de créditos previos (credit_history). El algoritmo utiliza este bloque de datos para "afinar" el perfil del solicitante, buscando patrones de comportamiento y estabilidad a mediano plazo antes de emitir un dictamen.

Por último, el reporte demuestra que variables como el tipo de empleo (job), si es trabajador extranjero (foreign_worker) o si tiene otros planes de pago (other_payment_plans) tienen un impacto casi nulo (menor a 0.02). Random Forest detecta de forma automática que estos datos aportan más ruido que valor real, por lo que reduce su importancia al mínimo para evitar equivocaciones.

Gracias a estos resultados, queda demostrado que nuestro modelo elegido es completamente transparente y explicable. Sabemos con certeza qué hilos está moviendo por dentro para aprobar o rechazar un crédito, cumpliendo así con las exigencias de auditoría del proyecto.


VII. Despliegue del Sistema del Proyecto de Aprendizaje Estadístico

Una vez completada la fase de modelado y evaluación del sistema de clasificación de riesgo crediticio, el siguiente paso consiste en poner el sistema a disposición de los usuarios finales. Esta etapa, conocida como despliegue, abarca tanto la publicación del código fuente y la documentación del proyecto en una plataforma de control de versiones, como la puesta en marcha de una aplicación web accesible desde cualquier navegador. Para ello se emplearon dos herramientas complementarias: GitHub, como repositorio central del proyecto, y Streamlit Community Cloud, como plataforma de hospedaje gratuito de la aplicación web.

7.1. Publicación del Proyecto y del Sistema en GITHUB

GitHub es una plataforma de alojamiento de código basada en el sistema de control de versiones Git. Permite registrar el historial completo de cambios realizados sobre un proyecto, colaborar con otros desarrolladores y servir como punto de distribución tanto del código fuente como de la documentación asociada. Para este proyecto se creó un repositorio público que centraliza todos los recursos necesarios para comprender, reproducir y ejecutar el sistema de clasificación de riesgo crediticio basado en Random Forest con el conjunto de datos German Credit.

El repositorio se organiza en tres secciones principales que corresponden a las pestañas nativas de GitHub: la pestaña de documentación, la pestaña de código y la pestaña de ejecución y pruebas, descritas a continuación.



7.1.1. Pestaña de Documentación del Proyecto

La documentación del proyecto se presenta principalmente a través del archivo README.md, que GitHub renderiza automáticamente en la página de inicio del repositorio. Este archivo cumple la función de carta de presentación del proyecto y contiene toda la información necesaria para que cualquier persona, independientemente de su nivel técnico, pueda entender de qué trata el sistema, con qué datos trabaja y cómo utilizarlo.

El archivo README.md incluye los siguientes apartados:

- **Descripción del proyecto:** Descripción general del problema de clasificación de riesgo crediticio y el objetivo del modelo.
- **Dataset utilizado:** Explicación del conjunto de datos German Credit de la UCI, incluyendo el significado de cada variable y sus posibles valores codificados.
- **Metodología aplicada:** Detalle del proceso seguido, desde el balanceo con SMOTE hasta la división 70/30 y el entrenamiento con Random Forest.
- **Estructura del repositorio:** Descripción de los archivos del repositorio, sus nombres y su propósito dentro del flujo de trabajo.
- **Instrucciones de instalación y uso:** Instrucciones paso a paso para instalar las dependencias y ejecutar la aplicación de forma local.

- **Resultados obtenidos:** Métricas de desempeño obtenidas en el conjunto de prueba, incluyendo precisión global, recall de morosos y AUC-ROC.



Adicionalmente, dentro del repositorio se incluye una carpeta llamada docs/ que contiene el informe técnico completo del proyecto en formato PDF, el diccionario de datos con la descripción de cada columna del dataset, y un archivo con los resultados de la evaluación del modelo. Esta carpeta permite que cualquier revisor o evaluador acceda a la documentación formal sin necesidad de ejecutar ningún código.


7.1.2. Pestaña de Código del Sistema

La pestaña de código, denominada Code en GitHub, aloja todos los archivos fuente necesarios para reproducir el sistema desde cero. La estructura de carpetas del repositorio se diseñó de forma modular para separar claramente cada etapa del pipeline de aprendizaje automático.

Los archivos principales del repositorio son los siguientes:

- **modelo_credificio.ipynb:** Cuaderno de Google Colab con el pipeline completo de preprocesamiento, aplicación de SMOTE, entrenamiento del modelo Random Forest, evaluación con métricas y exportación del modelo entrenado.
- **modelo_credificio.pkl:** Archivo binario que contiene el modelo Random Forest ya entrenado, serializado con la librería joblib. Este archivo es cargado por la aplicación web en cada sesión para realizar predicciones sin necesidad de reentrenar.

- **columnas_modelo.pkl:** Archivo que almacena la lista de columnas en el orden exacto que espera el modelo, garantizando coherencia entre el entrenamiento y la inferencia.
- **app.py:** Código fuente de la aplicación web desarrollada con Streamlit. Contiene la lógica de carga del modelo, procesamiento del archivo CSV subido por el usuario y visualización de los resultados de clasificación.
- **requirements.txt:** Archivo de texto que lista todas las dependencias de Python necesarias para ejecutar la aplicación, incluyendo scikit-learn, imbalanced-learn, streamlit, pandas y joblib.
- **data/plantilla_clientes.csv:** Archivos CSV de ejemplo con datos de clientes en el formato correcto, listos para ser cargados en la aplicación y usados como prueba de funcionamiento.



anthonyepv-ctrl Update README.md			80cc464 · 4 minutes ago	🕒 5 Commits
📄 README.md	Update README.md			4 minutes ago
📄 app.py	Add files via upload			5 days ago
📄 columnas_modelo.pkl	Add files via upload			5 days ago
📄 modelo_credificio.pkl	Add files via upload			5 days ago
📄 requirements.txt	Add files via upload			5 days ago

Cada archivo incluye comentarios internos que explican la función de cada bloque de código, lo que facilita su lectura y mantenimiento. El uso de GitHub como repositorio garantiza además que cualquier modificación futura quede registrada en el historial de commits, permitiendo revertir cambios si fuera necesario.

7.1.3. Pestaña de Ejecución y Pruebas del Sistema

Para facilitar la reproducibilidad del experimento, el cuaderno principal del proyecto fue desarrollado en Google Colab y vinculado directamente al repositorio de GitHub mediante la integración nativa entre ambas plataformas. Esto permite que cualquier persona con acceso al repositorio pueda abrir el cuaderno en Colab con un solo clic, sin necesidad de instalar ningún software localmente.

Dentro del cuaderno se documentan y ejecutan las siguientes etapas de prueba del sistema:

- **Carga y exploración de datos:** Carga del dataset German Credit directamente desde el repositorio de la UCI, verificando la integridad de los datos y la distribución original de clases (700 buenos, 300 malos).
- **Balanceo con SMOTE:** Aplicación del algoritmo SMOTE sobre el conjunto de entrenamiento para equilibrar las clases al 50%, con verificación visual de la distribución resultante.
- **Entrenamiento y evaluación:** Entrenamiento del modelo Random Forest con 100 estimadores sobre los datos balanceados y evaluación sobre el conjunto de prueba (30% de los datos originales).
- **Métricas de desempeño:** Generación de la matriz de confusión, reporte de clasificación con precisión, recall y F1-score, y cálculo del índice AUC-ROC para medir la capacidad discriminativa del modelo.
- **Prueba con datos nuevos:** Prueba del sistema con un conjunto de 1000 clientes sintéticos con distribución conocida (650 buenos, 350 malos), contrastando los resultados del modelo contra la distribución real para estimar su precisión en producción.

The screenshot shows a Jupyter Notebook titled 'AE_Proyecto.ipynb'. The code in the cell imports pandas and numpy, then loads the 'german.data' dataset from the UCI archive. It defines a list of columns and reads the CSV file. The code then maps the 'clase' column to 0 for 'Buen cliente' and 1 for 'Mal cliente'. Finally, it prints the shape of the dataset, the distribution of classes, and the first few rows of the data frame.

```
import pandas as pd
import numpy as np

# Cargar dataset German Credit directamente desde UCI
url = "https://archive.ics.uci.edu/ml/machine-learning-databases/statlog/german/german.data"

columnas = [
    'estado_cuenta', 'duracion', 'historial_credito', 'proposito', 'monto_credito',
    'cuenta_ahorro', 'empleo', 'tasa_cuota', 'estado_personal', 'otros_deudores',
    'residencia', 'propiedad', 'edad', 'otros_planes', 'vivienda',
    'creditos_existentes', 'trabajo', 'personas_cargo', 'telefono',
    'trabajador_extranjero', 'clase'
]

df = pd.read_csv(url, sep=' ', header=None, names=columnas)

# Clase: 1=Buen cliente, 2=Mal cliente → convertir a 0 y 1
df['clase'] = df['clase'].map({1: 0, 2: 1}) # 0=No moroso, 1=Moroso

print("Shape del dataset:", df.shape)
print("\nDistribución de clases:")
print(df['clase'].value_counts())
df.head()
```

Output:

```
*** Shape del dataset: (1000, 21)

Distribución de clases:
clase
0    700
1    300
Name: count, dtype: int64
```

	estado_cuenta	duracion	historial_credito	proposito	monto_credito	cuenta_ahorro	empleo	tasa_cuota	estado_personal
0	A11	6	A34	A43	1169	A65	A75	4	
1	A12	48	A32	A43	5951	A61	A73	2	
2	A14	12	A34	A46	2096	A61	A74	2	
3	A11	42	A32	A42	7882	A61	A74	2	
4	A11	24	A33	A40	4870	A61	A73	3	

```

from sklearn.preprocessing import LabelEncoder

# Separar features y target
X = df.drop('clase', axis=1)
y = df['clase']

# Codificar variables categóricas (texto → número)
le = LabelEncoder()
for col in X.select_dtypes(include='object').columns:
    X[col] = le.fit_transform(X[col])

print("Variables después de codificar:")
print(X.dtypes)

```

Variables después de codificar:

estado_cuenta	int64
duracion	int64
historial_credito	int64
proposito	int64
monto_credito	int64
cuenta_ahorro	int64
empleo	int64
tasa_cuota	int64
estado_personal	int64
otros_deudores	int64
residencia	int64
propiedad	int64
edad	int64
otros_planes	int64
vivienda	int64
creditos_existentes	int64
trabajo	int64
personas_cargo	int64
telefono	int64
trabajador_extranjero	int64
dtype:	object

```

# División 70% entrenamiento / 30% testing (ANTES de SMOTE)
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.30,
    random_state=42,
    stratify=y # mantiene proporción de clases
)

print("Antes de SMOTE:")
print("Entrenamiento:", X_train.shape, "| Distribución:", y_train.value_counts().to_dict())

# Aplicar SMOTE SOLO al conjunto de entrenamiento
smote = SMOTE(random_state=42)
X_train_smote, y_train_smote = smote.fit_resample(X_train, y_train)

print("\nDespués de SMOTE:")
print("Entrenamiento:", X_train_smote.shape, "| Distribución:", y_train_smote.value_counts().to_dict())
print("Testing (sin tocar):", X_test.shape)

```

Antes de SMOTE:
Entrenamiento: (700, 20) | Distribución: {0: 490, 1: 210}

Después de SMOTE:
Entrenamiento: (980, 20) | Distribución: {1: 490, 0: 490}
Testing (sin tocar): (300, 20)

```

from sklearn.ensemble import RandomForestClassifier

# Modelo Random Forest
rf_model = RandomForestClassifier(
    n_estimators=100, # 100 árboles
    max_depth=None, # árboles sin límite de profundidad
    random_state=42,
    class_weight='balanced' # doble protección contra desbalance
)

rf_model.fit(X_train_smote, y_train_smote)
print("✅ Modelo entrenado correctamente")

```

✅ Modelo entrenado correctamente

```

# Predicciones
y_pred = rf_model.predict(X_test)
y_proba = rf_model.predict_proba(X_test)[:, 1]

# Reporte completo
print("="*50)
print("      REPORTE DE CLASIFICACIÓN")
print("="*50)
print(classification_report(y_test, y_pred, target_names=['No Moroso', 'Moroso']))
print(f"AUC-ROC: {roc_auc_score(y_test, y_proba):.4f}")

# Matriz de confusión
fig, ax = plt.subplots(figsize=(6,5))
ConfusionMatrixDisplay.from_predictions(
    y_test, y_pred,
    display_labels=['No Moroso', 'Moroso'],
    cmap='Blues', ax=ax
)
plt.title("Matriz de Confusión - Random Forest")
plt.tight_layout()
plt.show()


```

```

=====
      REPORTE DE CLASIFICACIÓN
=====

```

	precision	recall	f1-score	support
No Moroso	0.82	0.86	0.84	210
Moroso	0.62	0.56	0.59	90
accuracy			0.77	300
macro avg	0.72	0.71	0.71	300
weighted avg	0.76	0.77	0.76	300



7.2. Deploy del APP o Web del Sistema de Predicción, de Clasificación, de Segmentación o Asociación.

El despliegue de la aplicación web constituye la etapa final del ciclo de vida del proyecto, en la cual el modelo entrenado se pone a disposición de usuarios finales a través de una interfaz accesible desde cualquier navegador, sin necesidad de instalar software ni conocer programación. Para este propósito se utilizó Streamlit, un framework de Python orientado a la construcción rápida de aplicaciones de datos e inteligencia artificial, y Streamlit Community Cloud como plataforma de hospedaje gratuito.

La arquitectura de despliegue sigue un flujo sencillo: Streamlit Community Cloud lee directamente los archivos del repositorio de GitHub, instala automáticamente las dependencias listadas en requirements.txt y levanta la aplicación en un servidor en la nube. Cualquier actualización que se realice en el repositorio se refleja automáticamente en la aplicación publicada, lo que simplifica el mantenimiento y la incorporación de mejoras futuras.

La aplicación web ofrece las siguientes funcionalidades al usuario:

- **Carga de datos:** El usuario carga un archivo CSV con los datos de uno o varios clientes en el formato que establece el dataset German Credit UCI. La aplicación valida automáticamente las columnas y las codifica de forma compatible con el modelo.
- **Clasificación automática:** El modelo Random Forest serializado procesa cada registro y produce dos salidas por cliente: la clase predicha (moroso o no moroso) y la probabilidad asociada a esa clasificación expresada en porcentaje.
- **Visualización de resultados:** Los resultados se presentan en una tabla interactiva donde cada cliente aparece etiquetado con un indicador visual en verde para los no morosos y en rojo para los morosos, acompañado de una barra de probabilidad de riesgo.
- **Resumen ejecutivo:** La parte superior de la página muestra un resumen con el total de clientes analizados, la cantidad clasificada como buenos pagadores y la cantidad identificada como posibles morosos.

Opción 1: Subir archivo CSV

Sube tu archivo con datos del cliente

clientes_1000.csv

76.3KB

Sistema de Evaluación de Riesgo Crediticio

Dataset: German Credit | Modelo: Random Forest + SMOTE

Opción 2: Ingresar datos manualmente

Duración del crédito (meses)

12

Tiempo de empleo

A73

Monto del crédito

5000

Historial crediticio

A30

Edad del cliente

35

Propósito

A40

Tasa de cuota (%)

7

Clasificar Cliente

Opción 1: Subir archivo CSV

Sube tu archivo con datos del cliente

clientes_1000.csv

76.3KB

2	NO MOROSO	47.0%
3	NO MOROSO	20.0%
4	MOROSO	54.0%
5	NO MOROSO	21.0%
6	NO MOROSO	40.0%
7	NO MOROSO	21.0%
8	NO MOROSO	40.0%
9	MOROSO	70.0%

Total clientes

1000

No Morosos

687

Morosos

313

El proceso de despliegue en Streamlit Community Cloud requirió los siguientes pasos: crear una cuenta en share.streamlit.io, vincular la cuenta de GitHub, seleccionar el repositorio del proyecto, indicar el archivo `app.py` como punto de entrada y confirmar el despliegue. Una vez completado este proceso, la plataforma genera una URL pública permanente con el formato `nombreusuario-nombrerepo.streamlit.app`, desde la cual cualquier persona puede acceder a la aplicación sin costo adicional.

La elección de Streamlit como framework de despliegue responde a tres criterios principales. En primer lugar, permite desarrollar la interfaz web completamente en Python, eliminando la necesidad de conocimientos en HTML, CSS o JavaScript. En segundo lugar, ofrece componentes listos para usar como cargadores de archivos, tablas de datos y gráficas que reducen significativamente el tiempo de desarrollo. En tercer lugar, su integración nativa con Streamlit Community Cloud facilita el despliegue en producción en pocos minutos y sin costo, lo que lo convierte en la opción más adecuada para proyectos académicos con restricciones de presupuesto.

En síntesis, la combinación de GitHub como repositorio de código y documentación, Google Colab como entorno de entrenamiento y prueba, y Streamlit Community Cloud como plataforma de despliegue conforman un stack tecnológico completamente gratuito, reproducible y accesible que permite llevar el modelo de clasificación de riesgo crediticio desde la fase experimental hasta un sistema funcional disponible para cualquier usuario con acceso a internet.

REFERENCIAS BIBLIOGRÁFICAS:

López, I. (2019). Credit scoring. Diccionario económico.

<https://www.expansion.com/diccionario-economico/credit-scoring.html>

Sánchez Bilbao, P. (2015). Credit scoring [Trabajo de fin de grado, Universidad de Cantabria]. Universidad de Cantabria.

<https://repositorio.unican.es/xmlui/bitstream/handle/10902/8056/SANCHEZBILBAOPABLO.pdf?sequence>

Tineo, V. A. D., & Chuquipul Ruiz, E. (2008). Aplicación del modelo del credit scoring a las tarjetas de crédito en Lima Metropolitana: Caso de un banco peruano [Trabajo de investigación para optar el grado de Magíster en Finanzas]. Lima, Perú.

<https://repositorio.up.edu.pe/backend/api/core/bitstreams/f7c5a676-abd7-45f9-88c9-e2ad1fc31fea/content>

Anderson, R. (2007). *The Credit Scoring Toolkit: Theory and Practice for Retail Credit Risk Management and Decision Automation*. OUP Oxford.

<https://books.google.com.pe/books?id=mp0SDAAQBAJ&printsec=front>

Tamayo Medrano, P. A. R. (2017). Credit scoring para la cartera crediticia de consumo no revolvable de una entidad bancaria estatal [Tesis de maestría, Universidad del Pacífico]. Repositorio Institucional de la Universidad del Pacífico.

<https://repositorio.up.edu.pe/item/11f67deb-f8b1-4c53-ab6c-f2bcd3ade843>

Rayo Cantón, S., Lara Rubio, J., & Camino Blasco, D. (2010). Un modelo de credit scoring para instituciones de microfinanzas en el marco de Basilea II. *Journal of Economics, Finance and Administrative Science*, 15(28), 89–124.

http://www.scielo.org.pe/scielo.php?pid=S2077-18862010000100005&script=sci_arttext&tlng=es

Gutiérrez Girault, M. A. (2007). Modelos de credit scoring: qué, cómo, cuándo y para qué. Munich Personal RePEc Archive (MPRA). <https://ideas.repec.org/p/pramprapa/16377.html>

IBM. (s. f.). What is random forest? IBM.

https://www.ibm.com/think/topics/random-forest?utm_source

IBM. (s. f.). What is gradient boosting? IBM.
https://www.ibm.com/think/topics/gradient-boosting?utm_source

Openbank. (s.f.). Qué es scoring bancario y cómo calcularlo.
<https://www.openbank.es/open-to-learn/scoring-bancario>

Gamco. (2022). Qué es el credit scoring y por qué la Inteligencia Artificial lo mejora. <https://gamco.es/que-es-credit-scoring-2/>

Mapfre. (2023). Qué es el puntaje crediticio y cómo mejorarlo.
<https://www.mapfre.com/actualidad/economia/puntaje-crediticio/>

Bank of America – Better Money Habits. (2026). ¿Cómo se calcula y se conforma un puntaje de crédito? <https://bettermoneyhabits.bankofamerica.com/es/credit/how-credit-score-is-calculated>

SciELO – Análisis del credit scoring (2013).
<https://www.scielo.br/j/rae/a/QVqpxMsxDppd6xPFcbnHKcK/>

Documentación Fundación Mapfre. (s.f.). Desarrollo y validación de modelo de scoring de morosidad.
<https://documentacion.fundacionmapfre.org>

Comité de Basilea. (2017). Basilea III: Marco reglamentario global para reforzar los bancos y sistemas bancarios. Banco de Pagos Internacionales. https://www.bis.org/publ/bcbs189_es.pdf

García, M. D., Gázquez, J. C., & Marín, P. J. (2010). El credit scoring: Una revisión de su evolución y aplicaciones. Estudios de Economía Aplicada, 28(2), 1-22.
<https://www.redalyc.org/pdf/3607/360733608004.pdf>.

Dinh, K., & Kleimeier, S. (2006). Credit scoring for Vietnam's retail banking market : implementation and implications for transactional versus relationship lending. METEOR, Maastricht University School of Business and Economics. METEOR Research Memorandum No. 012 <https://doi.org/10.26481/umamet.2006012>

Kwofie, C., Owusu-Ansah, C., & Boadi, C. (2015). Predicción de la probabilidad de incumplimiento de préstamo: una aplicación de regresión logística binaria. Research Journal of Mathematics and Statistics, 7(4), 46-52. <https://www.napopen.com/article/rjms.7.2206>

Rayo, S., Lara, J., & Camino, D. (2010). Un modelo de credit scoring para instituciones de micro finanzas en el marco de Basilea II. *Journal of Economics, Finance and Administrative Science*, 15(28), 33-52. http://www.scielo.org.pe/scielo.php?pid=S2077-18862010000100005&script=sci_arttext&tlng=es